

AI-FMS PHASE I · 中文论文完整审阅初稿

超越 FMS 顺序分数： 四动作 Pilot 中基于姿态估计的人机协同动作策略分析

Beyond Ordinal FMS Scores: A Human-in-the-Loop Pose-Based Analysis of
Movement Strategy in a Four-Movement Pilot

学生作者：[Ronnie 正式发表姓名]

成人通信联系人：[姓名与 affiliation]

其他贡献者：[待按贡献与期刊政策确认]

版本：中文完整初稿 v0.1 · 2026-08-17

内部整体审阅稿 · 尚未提交期刊 · 不得表述为同行评审论文

目录

- | | |
|-----------|----------------|
| 1. 摘要与关键词 | 7. 声明、伦理与数据可用性 |
| 2. 1. 引言 | 8. 参考文献 |
| 3. 2. 方法 | 9. 附录 A：特征与质量门 |
| 4. 3. 结果 | 10. 附录 B：分析分母 |
| 5. 4. 讨论 | 11. 附录 C：主张边界 |
| 6. 5. 结论 | 12. 附录 D：复现命令 |

审阅说明： 本稿用于先整体检查论文问题、结构、结果与论证深度。正式英文稿将在 NHSJS 书面确认 AI-use、secondary-video ethics、成人联系人及 Zenodo preprint 政策后，按照其 Word 模板重新撰写和排版。

摘要

背景：Functional Movement Screen (FMS) 使用 0–3 的顺序分数 对动作完成情况进行归纳。该方法便于实际筛查，但一个单一分数无法完整保存动作 深度、关节贡献、左右差异、重复性、扣分路径和动作周期等连续信息。本研究开发并 评估了一套 human-in-the-loop 视频审核平台，探索 pose-derived quantitative evidence 能否在保留人工最终判断权的同时，恢复顺序分数压缩掉的动作信息。

方法：系统以 MediaPipe Pose Landmarker 为基础，连接视频动作 切片、人工盲评、动作特异性特征、规则式 AI suggestion 和可追踪数据导出。Phase I 研究覆盖 Deep Squat、Active Straight Leg Raise (ASLR)、Hurdle Step 和 Rotary Stability。研究从 28 个唯一源视频重建 110 个 canonical repetitions，其中 66 个 通过 pose/timing 质量门。两位 reviewer 对四动作各 8 条、共 32 条正式样本完成 两轮独立盲评。锁定 AI 通过与 Study Mode 隔离的路径处理同一批样本。研究另外采用 四种动作特异性探索方法：15-rep Deep Squat 连续谱、4-rep ASLR 双侧重复性序列、5-rep Hurdle 盲评扣分路径分类，以及 8-rep Rotary 周期事件矩阵。

结果：Round B 中两位 reviewer 对 32/32 条可评分状态判断一致；在双方均可评分的 26 条中，RAW SCORE 为 26/26 exact。最终锁定 AI 对 28/32 条 给出分数；在同时具有 AI 分数与人工数值共识的 25 条中，16/25 exact、23/25 相差不超过 1 分，MAE 为 0.44，linear weighted kappa 为 0.4917。动作特异性分析 显示：Deep Squat 的深度与髌膝屈曲形成较清楚的连续轴，但踝、躯干与对线保留 相对独立信息；ASLR 中相近的 active height 可伴随更大的固定腿与骨盆控制变化；五条 Hurdle 2 分动作形成四种不同 review pathway；Rotary 的触踝、伸展、时序与 回位必须在完整周期内解释。

结论：AI-FMS 的当前价值不是替代 reviewer 自动给分，而是把人工 顺序判断与连续、可解释、可追踪的动作证据放入同一工作流。结果支持开展进一步的 held-out 和 expert-panel 验证，但不支持医疗诊断、伤病预测或临床准确率主张。

关键词：Functional Movement Screen；human-in-the-loop；pose estimation；movement quality；video annotation；markerless motion analysis；ordinal score；interpretable AI

1. 引言

1.1 从动作筛查到视频审核

FMS 通过七种动作模式和 0–3 的顺序评分，帮助实践者以统一规则观察动作完成情况。既有系统综述通常认为 FMS 具有较好的 interrater 与 intrarater reliability，但同时 也提醒研究者区分“评分者能否一致给分”与“分数是否代表某种临床机制或未来伤病”。Cuchna 等人的 meta-analysis 报告了总体较好的评分可

靠性^[1]；Bonazza 等人则指出，尽管可靠性结果较好，construct validity 和 injury prediction 仍存在明显限制^[2]。更新版 FMS 的视频评分研究也表明，不同动作的 reliability 并不完全相同^[3]。

视频为动作审核提供了现场观察之外的能力：reviewer 可以暂停、回放、逐 rep 循环，也可以在远程或异步场景中复核。然而，如果视频最终只留下一个 0–3 分数，大量关于动作如何完成的信息仍会丢失。例如，两个同为 2 分的 Deep Squat 可能具有不同的动作深度、髌膝屈曲组合、踝部贡献和躯干策略；两个相同分数的动态动作也可能在左右侧、回收阶段或周期完整度上存在差异。

1.2 Markerless pose estimation 的机会与限制

Markerless pose estimation 可以从普通视频中提取人体关键点，为低成本动作分析提供基础。BlazePose 针对移动端和 fitness 场景设计了 33 个 body keypoints，并支持对单人视频进行实时或接近实时的姿态跟踪^[4]。单摄像机与开源 pose 系统有潜力降低运动分析门槛；相关研究已经展示了从普通视频预测部分定量运动指标的可行性^[6]，Sports2D 等工具也说明 2D keypoints 可以转化为可读的关节和肢段角度^[8]。

但 markerless measurement 不能被自动等同于 laboratory biomechanics。Camera view、遮挡、运动模糊、单人/多人主体选择、透视和 out-of-plane movement 都会改变测量质量。Colyer 等人的综述指出，markerless 技术具有实用潜力，但精度和适用边界必须结合任务与采集环境判断^[5]。Wade 等人进一步强调，部分时空指标已接近传统系统，但 joint center 和 joint angle 仍不应在缺少 gold-standard comparison 时被当作临床测量^[7]。

1.3 研究缺口与目的

现有讨论常把问题简化为“AI 能否自动给出 FMS 分数”。本研究采用不同定位：AI 首先是人工审核的 evidence layer，而不是最终决策者。Human–AI 系统应当说明何时有证据、何时不确定，并保持人工能够复核和覆盖系统输出^[10]。因此，本研究不把综合分数作为唯一结果，而是同时保存视频范围、rep timing、camera view、side、protocol condition、pose features、质量标志、人工判断和 AI abstention。

本研究提出四个探索性问题：


1. 能否建立一个覆盖七动作、支持人工最终判断且可追踪的 FMS 视频审核平台？
2. 两位 reviewer 在两轮独立盲评中的一致性与 test–retest stability 如何？
3. 锁定 AI 的 coverage、abstention 和与人工共识的 internal concordance 如何？
4. 不同动作的顺序分数分别压缩了哪些连续、双侧、规则路径或时间事件信息？

论文的核心主张：FMS 顺序分数并非“错误”，而是为了快速决策进行的有目的压缩。AI–FMS 的研究价值在于恢复部分被压缩的信息，并把这些信息转化为可以复核、比较和继续验证的 evidence，而不是用 AI 替代人工判断。

2. 方法

2.1 研究设计与系统范围

本研究为探索性观察型 software-and-data pilot。平台产品层覆盖全部七个 FMS 动作， 包含视频上传、分析范围、rep segmentation、loop playback、人工评分、pose overlay、 movement-specific features、first-pass AI suggestion、adjudication 和 JSON/CSV export。Phase I 定量研究聚焦四个具有较完整历史视频和 pose 证据的动作：Deep Squat、ASLR、Hurdle Step 和 Rotary Stability。



2.2 Canonical 数据重建

研究从 28 个 cumulative history exports 重建 canonical snapshot。相同内容的视频 通过 checksum 去 重，最终得到 29 个 ingest、28 个唯一源视频和 110 个 repetitions。 稳定 `videoid`、`ingestId` 和 `repetitionId` 根据内容和 lineage 派生。每条记录保留 动作类型、原 segment、时间范围、camera view、side、protocol metadata、video/pose checksum 及冲突状态。历史人工标签与 legacy AI 仅保留 为 provenance，不能作为 当前 AI 规则的输入。

动作	源视频	Reps	Blindable	Feature-ready	Formal	Round B consensus
Active Straight Leg Raise	7	17	11	11	8	6
Deep Squat	11	34	31	31	8	4
Hurdle Step	7	41	37	16	8	8
Rotary Stability	3	18	18	8	8	8
合计	28	110	97	66	32	26

表 1 | 四动作数据范围。Repetitions 嵌套于源视频，不能将 110 reps 解释为 110 名独立参与者。

2.3 Blindability 与 feature-readiness 质量门

所有 110 条 rep 均通过 start/middle/end contact-sheet 审核。画面中的直接数字分数、明确评分指导、目标人物错误或动作不可见会 fail closed。97 条 rep 被判为 blindable，13 条因可见分数线索、评分指导或构图不足被排除。历史 `cameraView` 经过 110/110 contact-sheet audit：65 条确认，45 条校正；分析使用独立的 `auditedCameraView`，不覆盖原始 lineage。

Feature quality gate 综合 pose frame coverage、missing-frame ratio、landmark visibility、timing cycle completeness、camera-view applicability 及多人物场景的目标主体/ROI QA。最终 66 条 feature-ready，44 条 limited。58 条同时通过 blindability 和 feature-readiness，正式样本从该池按动作平衡、源视频分散和固定策略冻结为 32 条。这一选择不是对完整 110-rep pool 的 simple random sample。

Evidence tier	Reps	用途
gold_consensus	26	Round B 两位 blind reviewers 均可评分且同分
formal_unscorable	6	双方均判为无法按 protocol 独立评分
expansion_candidate	26	同时通过双门槛但未进入正式审核
feature_ready_not_blindable	8	可用于无标签 feature analysis，不可进入 blind study
blindable_feature_limited	39	可观看，但 timing/pose evidence 不足
not_blindable_feature_limited	5	两类门槛均未通过

表 2 | Evidence tiers。完整 pool 被保留；不因正式样本较小而丢弃 前期数据，也不把未审核的 weak labels 升级为 gold labels。

2.4 双轮人工盲评

两位 reviewer 分别完成 Round A 和 Round B。第二轮在约 51 小时后进行，使用重新 随机的队列和独立存储 namespace。两轮均不显示源文件名、历史分数、AI suggestion、pose-derived features、上一轮答案、另一 reviewer 答案或音频。Reviewer 可选择 0–3 RAW SCORE 或 `unscorable`。`0` 仅代表已观察或报告的 pain；动作、机位或 protocol 条件不足必须记录为 `unscorable` 及原因。

Review events 为 append-only；修改产生新 event 并通过 `supersedesEventId` 关联。每份导出均与 SHA-256 配对，并经 schema、manifest、completion 和 blind-state validation 后幂等写入本地 SQLite。RAW SCORE agreement、MAE、confusion matrix 与 weighted Cohen's kappa 仅使用双方均给出数值分数的 reps。Weighted kappa 用于 对有序分值的不同距离赋予不同权重^[9]。

2.5 Pose-derived features 与锁定 AI

MediaPipe Pose Landmarker 生成 time-aligned landmarks。Action adapters 在脱敏后 的 pose payload 上提取 normalized distances、2D angles、trajectory proxies 和 cycle events。建议规则不接收 score-bearing filename、notes、历史分数、reviewer comments 或 legacy AI。早期 workflow 中

92 条 numeric AI suggestions 被标记为 `label-leakage-ineligible`，不进入任何 agreement 或 validation。

Frozen AI v1.0 在 Round B 前锁定；Final AI v1.1 在查看 Round B 结果前锁定，但其开发发生在 Round A 之后。因此 v1.1 只能称为 post-audit internal benchmark。AI 分析全部 32 条不等于强制给 32 个分数；当 Deep Squat floor attempt 缺少 FMS staged follow-up 时，系统保持 abstain。

2.6 动作特异性分析

四个动作并未套用同一个 pairwise template。分析问题、单位和方法由动作结构及可用证据决定：

动作	研究问题	方法	分析单位
Deep Squat	深度是否决定完整动作策略？	侧视连续谱、rep-level Spearman 与 source-median sensitivity	15 reps / 7 videos
ASLR	相似结果在左右侧与重复动作中是否稳定？	同源 bilateral repeatability series	4 good reps
Hurdle Step	同为 2 分是否代表同一种扣分原因？	Blind comments 主题编码与 quantitative ranges	5 reps / 5 videos
Rotary Stability	单一峰值帧能否表达复杂动作顺序？	Full-cycle event matrix	8 blind-reviewed reps

表 3 | 动作特异性分析设计。

2.7 伦理、隐私与数据边界

Pilot 使用既有本地和公开教学/reference videos，没有前瞻性招募参与者，也没有收集人口统计、临床诊断或 injury outcome。不同来源的公开与再发布权利尚未完全统一，因此本文初稿只使用聚合数值和无人物研究图。Raw videos、可识别帧、raw pose、reviewer comments、签名 exports 和 SQLite 均保持私有。正式投稿前需要目标期刊书面确认 secondary-video research 所需的 SRC/IRB/exemption/consent 与 rights 材料。

3. 结果

110	66	32	28
Canonical reps	Feature-ready	Formal blind sample	Final AI scores

3.1 人工一致性与复测稳定性

Round A 中两位 reviewer 的 outcome agreement 为 31/32。双方均可评分的 26 条 全部同分；5 条双方均为 unscorable，另有 1 条 scoreability mismatch。Round B 中 outcome agreement 提高到 32/32；双方均可评分的 26 条仍为 26/26 exact，6 条双方 均 unscorable 且 reason taxonomy 6/6 一致。两位 reviewer 各有 1 条数值变化， 且发生在同一条 Hurdle Step。由于可比较分数完全一致，Round A 与 Round B 的 linear 和 quadratic weighted kappa 均为 1.0000。

指标	Round A	Round B
Completed reviews	32 / reviewer	32 / reviewer
Status agreement	31/32	32/32
Jointly scorable	26	26
RAW SCORE exact	26/26	26/26
Both unscorable	5	6
Unscorable reason exact	2/5	6/6
Linear weighted kappa	1.0000	1.0000

表 4 | 双轮人工审核结果。高一致性受正式样本筛选、共同 protocol training、分值结构和只有两位 reviewer 等条件限制，不能外推为临床可靠性。

3.2 AI–Human Internal Concordance

Final AI v1.1 对正式 32 条中的 28 条给出 RAW SCORE，对 4 条 Deep Squat staged floor attempt 保持 abstain。人工 Round B 形成 26 条数值共识，AI 与人工数值共识的 交集为 25 条。整体 exact agreement 为 16/25，within-one agreement 为 23/25， MAE 为 0.44，linear weighted kappa 为 0.4917。按动作看，Deep Squat 当前只有 3 条可比较，不能因 3/3 exact 作强泛化；Hurdle 的主要差异集中在 2/3 边界；ASLR 存在少数严重低估；Rotary 有两条保守的 AI 1 / human 2 差异。

动作	Comparable	Exact	Within one	MAE
ASLR	6	4/6	4/6	0.6667
Deep Squat	3	3/3	3/3	0.0000
Hurdle Step	8	3/8	8/8	0.6250
Rotary Stability	8	6/8	8/8	0.2500
Overall	25	16/25	23/25	0.4400

表 5 | Final AI v1.1 与 Round B 人工共识。这是 post-audit internal benchmark，不是 held-out accuracy。AI coverage 与 agreement 分开报告。

3.3 Deep Squat：动作策略是连续谱

从 31 条 feature-ready Deep Squat 中保留 15 条审计后的 side-view reps，覆盖 7 个源视频。分析不使用人工分数，以 `peakDepthRatio` 为连续参考轴，同时计算 rep-level Spearman correlation 与按源视频取 median 后的 sensitivity。深度与 `kneeAngleDegrees`、`hipAngleDegrees` 和 `hipKneeVerticalGap` 呈较强方向关系；`ankleShankLeanDegrees`、`trunkLeanDegrees` 和 `maxKneeAnkleOffset` 与深度的关系较弱或在 rep/source 层方向不稳定。

Feature vs depth	Rep-level rho	Source-median rho	解释
hipKneeVerticalGap	0.700	0.750	深度增加时髌部相对膝部更低
hipAngleDegrees	-0.689	-0.821	深度与髌屈曲方向一致
kneeAngleDegrees	-0.850	-0.929	深度与膝屈曲关系最稳定
ankleShankLeanDegrees	-0.204	-0.107	与深度关系较弱
trunkLeanDegrees	-0.050	0.464	受来源影响，方向不稳定
maxKneeAnkleOffset	-0.118	-0.214	保留独立对线信息

表 6 | Deep Squat 连续谱的 rank correlations。



3.4 ASLR：从单次高度转向左右侧与重复性

一个五-rep 源视频中，四条通过 `good` side/peak gate，一条 `watch` 被排除。四条 good rep 均保留历史 3 分，其中三条另有稳定 blind consensus，剩余一条为 historical weak-label evidence。四条 active ankle height 只跨 0.2758–0.3053，但 stationary ankle drift 跨 4.25 倍，pelvic gap 跨 2.56 倍。按侧别取平均后，右侧 active height 低约 7.5%，stationary ankle drift 约为左侧的 2.4 倍，pelvic gap 约为 1.9 倍。

Rep	Active height	Stationary knee	Ankle drift	Pelvic gap	Label evidence
Left 1	0.3053	161.6	0.0100	0.0180	Stable blind consensus
Left 2	0.3009	174.9	0.0040	0.0251	Stable blind consensus
Right 1	0.2850	162.8	0.0170	0.0361	Stable blind consensus
Right 2	0.2758	164.5	0.0170	0.0460	Historical weak label

表 7 | ASLR bilateral repeatability series。

ASLR: Result, Side and Repeatability

One source · four good-evidence reps · left and right series



Active height varied modestly; stationary ankle drift varied 4.25x and pelvic gap 2.56x.
Three reps have stable blind consensus; one right rep retains a historical weak label. One watch-quality rep was excluded.

图 3 | ASLR 左右侧与重复性。相近的目标抬腿高度并不意味着固定腿 与 骨盆控制 proxy 也同步稳定。该结果只有一个来源，属于定向采集假设。

3.5 Hurdle Step: 同为 2 分，却有不同 review pathway

Round B 中有五条来自五个不同视频的 Hurdle rep 被两位 reviewer 一致判为 2 分。对 blind comments 进行结构化主题编码，并连接 pose-derived ranges 后，识别出四种 pathway：多领域控制、远端对线、回收阶段对线和单独的 dowel control。五条动作的 `peakClearance` 跨 1.43 倍，`stepKneeLineOffset` 跨 10.12 倍，`trunkCenterOffset` 跨 11.43 倍。

Pathway	Reps	Blind observation pattern	Quantitative context
Multi-domain control	1	对线、躯干、支撑腿和 dowel 同时出现问题	Trunk offset 0.0263，接近五条最高值
Distal alignment	2	躯干与支撑腿稳定，但膝盖/脚踝内移	Clearance 0.2061–0.2413
Return-phase alignment	1	峰值阶段完成，收腿阶段出现膝盖对线变化	Clearance 0.2956，为五条最高
Dowel control only	1	下肢和躯干稳定，主要问题为杆与栅栏不平行	Clearance 0.2225；trunk offset 0.0084

表 8 | Hurdle Step 2 分的四种 review pathway。

Five Score–2 Reps, Four Review Pathways

Hurdle Step · five independent videos · Round B blind consensus

One endpoint does not identify why the movement received that endpoint.

	Alignment	Ankle	Trunk	Support	Dowel	Return
2 Multi–domain control source 1 · mixed view	×		×	×	×	
2 Distal alignment source 2 · front view	×	×				
2 Return–phase alignment source 3 · mixed view	×					×
2 Distal alignment source 4 · front view	×	×				
2 Dowel control only source 5 · front view					×	

The follow–up question changes by pathway: alignment, single–leg stability, trunk control, or dowel control.

Themes are structured coding of blinded reviewer observations, combined with pose–derived ranges; they are not diagnoses.

图 4 | 五条 Hurdle 2 分动作的主题矩阵。同一个 2 分无法直接说明“为什么是 2 分”或应优先复核哪里；主题来自 blinded reviewer observations，不是自动诊断标签。

3.6 Rotary Stability：完整周期事件矩阵

Rotary 由 setup、第一次触踝、伸展、第二次触踝、回位和离地时序组成。八条正式 rep 包含四条人工 1 分和四条人工 2 分。人工 1 分组的第二次触踝与回位均为 4/4 fail；人工 2 分组的第一次触踝和肘膝伸展均保留，但其中两条在第二次触踝/回位仍有边界 证据，AI 因而保守提示 1 分。

Human score	First touch	Second touch	Elbow extension	Knee extension	Return	AI scores
1	1 pass / 3 fail	4 fail	3 pass / 1 watch	1 pass / 2 watch / 1 fail	4 fail	4 × score 1
2	4 pass	2 pass / 2 fail	4 pass	4 pass	2 pass / 2 watch	2 × score 2; 2 × score 1

表 9 | Rotary 的 cycle–event evidence 摘要。

Rotary Stability Needs a Timeline

8 blind-reviewed reps · 4 human score 1 · 4 human score 2 · cycle-event evidence

	Human	AI	Touch 1	Touch 2	Elbow	Knee	Return	Lift timing
Rep 1	1	1	F	F	P	W	F	?
Rep 2	1	1	F	F	W	F	F	?
Rep 3	1	1	F	F	P	P	F	?
Rep 4	1	1	P	F	P	W	F	?
Rep 5	2	2	P	P	P	P	P	F
Rep 6	2	1	P	F	P	P	W	?
Rep 7	2	2	P	P	P	P	P	W
Rep 8	2	1	P	F	P	P	W	?

Score 1: second touch and return failed in 4/4. Score 2: two clean cycle patterns and two conservative boundary flags.

P pass · W watch · F fail · ? unknown

图 5 | Rotary full-cycle event matrix。Rotary 隐藏的信息不是单一 角度，而是 contralateral coordination、动作顺序、完整伸展、触踝和回位控制的 组合；正式样本只来自两个视频，频率不能外推到总体人群。

3.7 历史标签审计

正式 32 条还被用于审计历史评分。25 条在两轮盲评中保持稳定数值共识，其中 18 条 与历史标签 exact，6 条稳定不一致，1 条历史分数缺失。只有 18 条可以标记为 `audited weak labels`；其余历史标签继续用于 provenance、抽样和假设生成，不能升级 为 gold labels。该结果说明前期 110-rep 工作可以继续产生价值，但 32 条目的性平衡 样本不能证明全部历史标签有效。

4. 讨论

4.1 分数压缩的不是同一种信息

本研究最重要的结果并不是“同分参数不同”这一句话，而是四个动作分别暴露了四类 信息压缩。Deep Squat 主要表现为连续关节贡献与动作策略；ASLR 表现为左右侧与 repeatability；Hurdle Step 表现为到达同一分数的不同扣分路径；Rotary Stability 表现为事件顺序与周期完整度。统一的 FMS 分值便于规则决策，但动作特异性的定量 evidence 才能进一步回答“动作是如何完成的”。

动作	顺序分数压缩的信息	AI-FMS 恢复的研究对象
Deep Squat	连续关节贡献与动作策略	深度轴与踝、躯干、对线等相对独立维度
ASLR	左右侧差异与重复动作稳定性	Bilateral profile 与 repeatability
Hurdle Step	到达同一分数的不同扣分原因	Review pathway 与定向 follow-up
Rotary Stability	事件顺序、周期完整度与边界证据	Cycle-level temporal evidence

表 10 | 跨动作的信息恢复框架。

4.2 人工一致性与 AI 一致性必须分开解释

两位 reviewer 在 Round B 对全部可评分状态和共同可评分分数达到完全一致，这说明 在本样本、本 protocol training 和本研究条件下，人工流程具有较高内部稳定性。但两位 reviewer 不能代表 certified expert panel，也不能推断不同背景 reviewer population 的 reliability。高 exact agreement 还会受到正式样本选择和分数分布影响。

Final AI 的 16/25 exact 和 23/25 within one 提供了一个有边界的内部 benchmark。它说明当前规则可为多数正式样本提供与人工相同或相邻的 first-pass suggestion；同时，ASLR 的少数大偏差、Hurdle 的 2/3 边界和 Deep Squat staged protocol abstention 都表明 AI 不能替代 reviewer。Final v1.1 接触过 Round A 后的开发过程，因此不能用 同一 32 条宣称 held-out accuracy。

4.3 Abstention 与质量门是系统能力

在自动评分叙事中，coverage 经常被误解为“所有样本都必须给分”。本研究将 evidence quality 与 score availability 分开。当 Deep Squat floor attempt 未满足最高分且没有 heels-elevated follow-up 时，规则无法确定最终 staged score；合理行为是 abstain，而不是根据单段 pose 强行猜测。类似地，ASLR active-side/peak gate 和 Hurdle camera-view applicability 也要求系统明确说明证据边界。

4.4 工程贡献与研究贡献的关系

AI-FMS 的工程贡献不是单一模型，而是把 video、rep、pose、human review、AI suggestion、quality gate 和 export 连接成可追踪流程。稳定 ID、append-only events、signed JSON/SHA-256、SQLite idempotency、manifest 与生成脚本使结果能够回到具体 证据。该设计遵循 human-AI interaction 中“让用户理解系统能力与限制、支持纠正和 保持人工控制”的一般原则^[10]。

研究贡献则来自该流程能够保存传统分数之外的信息。换言之，工程系统使定量观察 可追溯，动作分析再把这些观察转化为可检验的问题。两者共同形成从产品 prototype 到 exploratory research 的闭环。

4.5 主要限制

1. **Sampling:** 110 reps 嵌套于 28 个源视频，不是 110 名独立 participants；动作、机位和来源分布不平衡。
2. **Reviewer:** 只有两位 reviewer，且没有 certified expert panel； 不能把内部一致性外推到专业群体。

3. **Measurement:** 2D pose 受 camera view、遮挡、透视、服装、主体 选择和 landmark jitter 影响；当前 features 是 video-derived proxies，不是临床 goniometric measurement。
4. **Validation:** Final AI 在 Round A 后开发，不是 held-out；Round B 也没有展示 AI evidence，因此不能检验 AI 是否提高人工效率、信心或准确性。
5. **Case analyses:** Deep Squat reps 嵌套于 7 个视频；ASLR series 只有一个来源且含一条 weak label；Hurdle pathways 来自人工主题编码；正式 Rotary subset 只来自两个视频。
6. **Ethics and rights:** 来源视频的再发布授权不完全一致，当前不能公开 原视频、可识别帧、raw pose 或 reviewer comments。

4.6 下一阶段研究

下一阶段不应盲目增加 rep 数，而应围绕已识别的问题采集独立证据：使用主体明确、side 与 peak 可见的 ASLR 视频验证 bilateral profile；使用完整轨迹和清晰 dowel 的 Hurdle 视频验证 pathway；使用手脚无遮挡、board alignment 可见的 Rotary 视频验证 cycle events；并以新的 source video 或 participant 为分组单位冻结 held-out set。

此外，可引入更多 reviewer 或 certified expert panel。如果要检验 AI 对人工审核的实际帮助，应另设 evidence-assisted controlled study，将盲评组与可见 AI evidence 组分开，预先定义 accuracy、confidence、time 和 correction outcomes。

5. 结论

本研究建立了一套覆盖七个 FMS 动作的人机协同视频审核平台，并在四动作 Phase I pilot 中连接了 canonical data、MediaPipe pose、双轮人工盲评、锁定 AI comparison 和动作特异性定量分析。两位 reviewer 在 Round B 中对 32/32 条可评分状态判断一致，并在共同可评分的 26 条中全部同分。最终锁定 AI 对 28/32 条给出分数；与人工数值 共识交集的 25 条中，16 条 exact、23 条 within one。

四种分析进一步表明，FMS 顺序分数可能分别压缩连续动作策略、左右与重复性、规则 扣分路径和时间事件顺序。AI-FMS 的价值不是把人工分数替换成另一个自动分数，而是 把这些连续、可解释、可追踪的 movement evidence 保存下来，并在证据不足时主动 abstain。当前结果支持一项有边界的 exploratory pilot 结论，不支持医疗诊断、伤病 预测、临床推广或 autonomous FMS scoring。

最终结论：人工 ordinal judgment 与 pose-derived quantitative evidence 可以被放入同一套可复核工作流；不同动作需要不同的分析问题与证据结构。这一结果为后续 held-out validation、expert review 和 responsible sports technology research 提供了方法基础。

声明、伦理与数据可用性

作者贡献（待人工确认）

Ronnie: [研究问题与项目动机、FMS protocol 学习、研究设计参与、Reviewer A 盲评、结果解释、论文撰写与最终批准，待逐项确认]。Other Reviewer: [独立盲评、方法和结果审阅，是否满足作者资格待确认]。成人 advisor: [监督、伦理与权利审核、关键学术审阅及通信职责，待确认]。

AI 使用披露

MediaPipe Pose Landmarker 被用于 pose estimation。OpenAI Codex 作为 AI coding agent，被用于辅助软件实现、可复现数据流程、分析脚本、研究图表，以及内部文档的起草或编辑。人类参与者确定研究方向、完成盲评、检查证据与输出、解释结果，并对提交的工作承担责任。Codex 不是作者。正式投稿前将根据目标期刊书面回复调整披露格式，但不会淡化 AI 实际参与范围。医学期刊编辑规范同样强调，AI 工具不能承担作者责任，使用方式应透明披露^[11]。

伦理审批与同意

本研究没有前瞻性招募参与者，也没有收集人口统计或临床结局。Pilot 使用既有本地和公开 instructional/reference videos。正式投稿前将向 NHSJS 书面确认 secondary video analysis 所需的 SRC、IRB、exemption、consent 和 rights documentation。在确认前，本稿不声称伦理审查豁免。

数据与代码可用性

Source code、schema、聚合图和 public-safe methods 可在 rights/privacy 审核后通过 GitHub release 提供。Raw videos、可识别帧、raw pose landmarks、reviewer comments、signed exports 和本地 SQLite 不公开。Canonical data 与分析输出通过稳定 ID、SHA-256、manifest 和生成脚本保存于 private research archive。

利益冲突与资金

[待人工作者确认。当前草稿未记录外部商业资助或利益冲突。]

致谢

感谢参与独立盲评、FMS protocol 讨论、数据审核和项目复核的人员。正式致谢名单需在获得本人同意后填写。

参考文献

1. Cuchna JW, Hoch MC, Hoch JM. The interrater and intrarater reliability of the Functional Movement Screen: a systematic review with meta-analysis. *Physical Therapy in Sport*. 2016;19:57–65. doi:10.1016/j.ptsp.2015.12.002.

2. Bonazza NA, Smuin D, Onks CA, Silvis ML, Dhawan A. Reliability, validity, and injury predictive value of the Functional Movement Screen: a systematic review and meta-analysis. *American Journal of Sports Medicine*. 2017;45(3):725–732. doi:10.1177/0363546516641937.
3. Morgan R, LeMire S, Knoll L, et al. The Functional Movement Screen: exploring interrater reliability between raters in the updated version. *International Journal of Sports Physical Therapy*. 2023;18(3):737–745. doi:10.26603/001c.74724.
4. Bazarevsky V, Grishchenko I, Raveendran K, Zhu T, Zhang F, Grundmann M. BlazePose: on-device real-time body pose tracking. arXiv:2006.10204. doi:10.48550/arXiv.2006.10204.
5. Colyer SL, Evans M, Cosker DP, Salo AIT. A review of the evolution of vision-based motion analysis and the integration of advanced computer vision methods towards developing a markerless system. *Sports Medicine – Open*. 2018;4:24. doi:10.1186/s40798-018-0139-y.
6. Kidziński L, Yang B, Hicks JL, Rajagopal A, Delp SL, Schwartz MH. Deep neural networks enable quantitative movement analysis using single-camera videos. *Nature Communications*. 2020;11:4054. doi:10.1038/s41467-020-17807-z.
7. Wade L, Needham L, McGuigan P, Bilzon J. Applications and limitations of current markerless motion capture methods for clinical gait biomechanics. *PeerJ*. 2022;10:e12995. doi:10.7717/peerj.12995.
8. Pagnon D, Kim H. Sports2D: compute 2D human pose and angles from a video or a webcam. *Journal of Open Source Software*. 2024;9(101):6849. doi:10.21105/joss.06849.
9. Cohen J. Weighted kappa: nominal scale agreement with provision for scaled disagreement or partial credit. *Psychological Bulletin*. 1968;70(4):213–220. doi:10.1037/h0026256.
10. Amershi S, Weld D, Vorvoreanu M, et al. Guidelines for Human–AI Interaction. In: *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*. 2019:1–13. doi:10.1145/3290605.3300233.
11. International Committee of Medical Journal Editors. Use of Artificial Intelligence in Publishing: Use of AI by Authors. Accessed 2026-08-17. <https://www.icmje.org/recommendations/browse/artificial-intelligence/ai-use-by-authors.html>.

注：正式投稿前，以上参考文献须由人类作者逐篇打开、阅读、确认引用语境，并按 NHSJS numerical citation format 生成匿名标准引用版与 online-citation 版。

附录 A：动作特征与质量门

动作	主要 pose-derived evidence	主要质量门	解释边界
Deep Squat	Depth ratio、hip-knee gap、hip/knee angle、trunk lean、shank lean、knee-ankle offset	Side/front applicability；完整最低点与回位；floor/board condition	2D proxy，不等同关节活动度诊断
ASLR	Active ankle height、peak elevation、moving/stationary knee、stationary ankle drift、pelvic gap	Active-side stability；peak window；主体选择；遮挡	不能把一条 weak-label rep 当作 blind gold
Hurdle Step	Peak clearance、knee geometry、line offset、trunk center offset、hip-height gap、ankle drift	Camera-view applicability；完整前进与回收；目标人物	Pathway 为人工编码，不是病因分类
Rotary Stability	First/second touch、elbow/knee extension、lift timing、return/balance、trunk displacement	Core-cycle visibility；criterion-specific visibility；clearing/pain	正式样本来源少，触踝 proxy 保守

附录 B：分析分母与问题对应

数字	代表什么	不能被用来证明什么
110	完整 canonical repetitions	不是 110 名参与者，也不是 110 个 gold labels
97	通过 blindability gate	不代表 pose evidence 可靠
66	通过 pose/timing feature gate	不代表具有人工 gold score
58	同时通过 blindability 与 feature gate	不是最终 formal sample
32	平衡冻结的双轮 blind formal sample	不是对 110 的 simple random proof
26	Round B 双方均可评分且同分	不包含 unscorable，也不等同 expert panel
28	Final AI 有分数的正式样本	不代表 28 条都可与人工数值比较
25	Final AI 与人工数值共识交集	不是 held-out evaluation set
18	与稳定双轮共识 exact 的 audited weak labels	不能升级其余历史标签

附录 C：论文主张控制

主题	可以说	不能说
平台能力	七动作均有 first-pass pose-based AI suggestion workflow	七动作已经达到相同验证成熟度
人工结果	两位 reviewer 在本正式样本中高度一致	已经证明临床或跨群体 reliability
AI 结果	在 25 条内部可比较样本中 16 exact、23 within one	64% accuracy、临床准确率或 held-out performance
动作发现	顺序分数压缩了动作特异性的连续与时间信息	已经识别 validated impairment subtype
功能解释	可提出 mobility、stability、coordination 的复核假设	诊断功能障碍、疼痛原因或伤病风险
Round B	第二次独立盲评与 test-retest evidence	AI evidence 提高了人工效率或信心
Zenodo	经允许后的 publicly available preprint	peer-reviewed publication

附录 D：主要复现命令

```
npm run data:pilot:build
npm run data:pilot:features
npm run data:pilot:camera-views
npm run data:pilot:features:camera-audited
npm run data:pilot:utilization
npm run data:pilot:profiles:label-free
npm run study:profiles:round-a
npm run study:ai-evidence:round-a
npm run study:evidence:round-b
npm run study:rotary:v1-1
npm run study:ai:final-v1-1
npm run study:labels:audit
npm run release:phase-i:figures
npm run release:phase-i:manifest
npm run check
```

需要签名 reviewer exports 的 closeout 命令只在 private research environment 中运行。Raw media、raw pose 和本地 SQLite 不属于公开复现包。